

ĐỀ CƯƠNG ĐỒ ÁN CHUYÊN NGÀNH

Trường / Khoa	Trường Đại học Bách khoa, ĐHQG-HCM. Khoa Khoa học và Kỹ thuật Máy tính
Tên đề tài (VI)	Chuẩn hóa và phân giải địa chỉ tiếng Việt qua ranh giới thời gian hành chính: Bộ dữ liệu chuẩn và mô hình hai tầng có nhận biết phiên bản
Tên đề tài (EN)	Vietnamese Address Parsing and Resolution across an Administrative Temporal Boundary: A Benchmark Dataset and a Version-Aware Two-Stage Model
Ngành	Khoa học Máy tính
Môn học	CO4029 (2 tín chỉ), thời lượng 15 tuần
GVHD	TS. Quan Thanh Tho
Nhóm thực hiện	Nguyễn Quang Tùng; Nguyễn Quang Huy (2311202)
Phiên bản	Bản cập nhật sau buổi báo cáo tiến độ, tháng 9/2026

1. Giới thiệu

1.1 Bối cảnh

Địa chỉ là cầu nối giữa dữ liệu văn bản và không gian địa lý, và là đầu vào bắt buộc của giao vận, thương mại điện tử, đăng ký hành chính, và ứng cứu khẩn cấp. Địa chỉ do người Việt nhập vào có bốn đặc trưng gây khó:

- Thiếu trường.** Người dùng thường bỏ phường xã hoặc quận huyện, viết tắt không nhất quán ("TP.HCM", "TPHCM", "HCM", "Sài Gòn").
- Định vị bằng mốc.** Rất phổ biến trong thực tế: "gần cầu Sài Gòn", "ngã tư Hàng Xanh hướng Bình Thạnh", "đối diện chợ Bà Chiểu". Đây là tham chiếu vị trí mang tính tổ hợp, không có tên địa danh tường minh cho vị trí đích.
- Địa giới hành chính vừa thay đổi trên diện rộng.** Cải cách 2025 giảm số tỉnh từ 63 xuống 34 và bỏ cấp huyện, đồng thời sáp nhập và tách phường xã trên cả nước.
- Mơ hồ theo thời gian.** Đây là hệ quả trực tiếp của điểm 3 và là trọng tâm của đề tài. Trong nhiều năm tới, dữ liệu địa chỉ Việt Nam sẽ tồn tại đồng thời ở hai hệ quy chiếu hành chính, và bản thân một chuỗi địa chỉ có thể trộn lẫn cả hai.

1.2 Sự mơ hồ không gian và thời gian: bốn tình huống cốt lõi

Ký hiệu	Tình huống	Ví dụ nhu cầu thực tế
A	Cũ sang mới. Địa chỉ theo hệ cũ, cần ánh xạ sang hệ mới; một đơn vị cũ tách thành nhiều đơn vị mới	Doanh nghiệp chuyển đổi cơ sở dữ liệu khách hàng
B	Mới về cũ. Địa chỉ theo hệ mới, cần tra ngược về hệ cũ; một đơn vị mới gộp từ nhiều đơn vị cũ	Tra cứu hồ sơ đất đai, hộ tịch, sổ sách lưu trữ
C	Địa chỉ lai. Người dùng cập nhật một phần, ví dụ tên phường mới kèm quận cũ	Người dùng nhập liệu trong giai đoạn chuyển tiếp

Ký hiệu	Tình huống	Ví dụ nhu cầu thực tế
D	Trùng lặp danh pháp. Tên đơn vị trùng nhau giữa hai hệ nhưng trở tới phạm vi khác nhau	Khớp chuỗi cho kết quả sai mà không có dấu hiệu cảnh báo

Tình huống C là loại bản nhất: chuỗi không nhất quán nội tại nên không hệ tra bảng nào xử lý được. Tình huống D nguy hiểm nhất vì gây lỗi im lặng.

1.3 Phát biểu bài toán

Đầu vào: một chuỗi địa chỉ tiếng Việt tự do a, có thể thiếu trường, viết tắt, sai chính tả, mô tả bằng mốc, và viết theo hệ hành chính cũ, mới, hoặc lai.

Đầu ra:

- **T0 (parsing):** tập các span có nhãn theo schema hành chính Việt Nam.
- **T1 (phân loại hệ quy chiếu):** nhãn ba lớp {cũ, mới, lai} cho toàn chuỗi, kèm nhãn cấp trường cho trường hợp lai.
- **T2 (ánh xạ hai chiều):** tham chiếu hành chính không mơ hồ ở hệ đích, cùng mã đơn vị hành chính và tọa độ. Ánh xạ theo cả hai chiều cũ sang mới và mới sang cũ.
- **T3 (đối sánh thực thể qua thời gian, giai đoạn 2):** cho hai bản ghi địa chỉ viết theo hai hệ khác nhau, xác định chúng có trở tới cùng một địa điểm vật lý hay không.

1.4 Mục tiêu nghiên cứu

1. Xây dựng bộ dữ liệu benchmark địa chỉ tiếng Việt có nhãn span, có gắn nhãn hệ quy chiếu thời gian.
2. Xây dựng gazetteer đa phiên bản, trong đó mỗi thực thể hành chính mang khoảng thời gian hiệu lực.
3. Thiết lập hệ baseline có kiểm chứng, phủ ba thể hệ kiến trúc.
4. Đề xuất mô hình hai tầng có khả năng nhận thức chiều thời gian.
5. Định lượng năm giả thuyết nghiên cứu (mục 5.2).

1.5 Phạm vi thực hiện

Trong phạm vi: văn bản địa chỉ dân dụng và thương mại tại Việt Nam, thuộc một trong hai hệ quy chiếu hành chính trước và sau đợt cải cách 2025.

Ngoài phạm vi: OCR từ ảnh, địa chỉ tiếng nước ngoài, các đợt thay đổi địa giới trước 2025, định tuyến giao hàng, dữ liệu cá nhân thật của khách hàng.

1.6 Ràng buộc triển khai

Toàn bộ mô hình phải huấn luyện và vận hành được trên một GPU đơn 16GB (Colab free hoặc Kaggle), không phụ thuộc API trả phí ở đường chạy chính. Ràng buộc này được đặt ra để đảm bảo tính khả thi trong một học kỳ và khả năng tái lập của kết quả.

2. Cơ sở lý thuyết và khảo sát công trình liên quan

2.1 Các khái niệm nền

- **Address parsing:** bài toán gán nhãn chuỗi, tách một chuỗi địa chỉ tự do thành các span có nhãn theo schema hành chính. Thường mô hình hóa như sequence labeling hoặc span extraction.
- **Toponym resolution / geoparsing:** bước tiếp theo sau parsing, ánh xạ tên địa danh đã tách sang một thực thể duy nhất trong gazetteer, kèm mã đơn vị và tọa độ.
- **Gazetteer:** cơ sở tri thức về địa danh. Gazetteer có chiều thời gian (temporal gazetteer) gắn cho mỗi thực thể một khoảng thời gian hiệu lực thay vì chỉ lưu trạng thái hiện tại.
- **Temporal record linkage:** bài toán xác định hai bản ghi ở hai thời điểm khác nhau có cùng trở tới một thực thể hay không, khi giá trị thuộc tính của thực thể thay đổi theo thời gian.
- **Lỗi im lặng (silent error):** hệ thống trả về một kết quả có vẻ hợp lệ nhưng sai, và không phát ra bất kỳ tín hiệu cảnh báo nào. Đây là kiểu lỗi nguy hiểm nhất trong tình huống D.

2.2 Nhánh phân tích và phân giải địa chỉ

Công trình	Kiến trúc	Ngôn ngữ	Hạn chế với bối cảnh Việt Nam
Libpostal	CRF + averaged perceptron	Đa quốc gia	Cần pipeline tiền/hậu xử lý nặng; tài liệu không cho phép phát triển parser mới
Deepparse (arXiv:2311.11846)	LSTM Seq2Seq	20 nước huấn luyện, 41 nước zero-shot	Việt Nam không có trong cả hai danh sách; schema 8 nhãn không có cấp phường xã
Yassine et al. (arXiv:2112.04008)	LSTM + attention, domain adversarial	Như trên	Địa chỉ thiếu trường làm hiệu năng tụt 20 đến 40%
GTBERT-Pointer (IJDE 2025)	BERT + gazetteer/type adapter + global pointer	Tiếng Trung	Cơ chế cập nhật động chỉ ghi đề gazetteer, không phiên bản hóa; không phân biệt được hệ quy chiếu
Hu et al. (IJGIS 2026)	LLM 7B fine-tune + geocoder	Tiếng Anh	Bộ dữ liệu lịch sử WOTR là ngoại lệ duy nhất mà phương pháp không thắng
Hu et al. (GeoExT 2025)	LLM + RAG, suy luận song song	Tiếng Anh	Xếp hạng ứng viên chỉ dùng tương đồng chuỗi và dân số
Masis và O'Connor (arXiv:2510.08741)	Geoparser + LLM reasoner	Tiếng Anh	Tự nêu hạn chế chỉ một dataset, chỉ tiếng Anh
vietnamadminunits	Dựa luật, tra bảng	Tiếng Việt	Phường cũ tách nhiều phường mới giải bằng cờ mặc định; chỉ hỗ trợ một chiều

Nhận xét chung: không công trình nào trong nhánh này có khái niệm thời gian ở tầng mô hình. Baseline tiếng Việt hiện có (vietnamadminunits) chỉ dựa trên luật cứng và không hỗ trợ nội suy hai chiều.

Về việc dùng LLM cho tác vụ parsing đơn lẻ, các công trình gần đây đã cho thấy giới hạn: AddrLLM tinh chỉnh toàn tham số trên Qwen-7B có chi phí quá cao, còn CapICL dùng GPT-3 vẫn

thua các mô hình nền BERT dù số tham số lớn hơn nhiều bậc. Kết luận này là căn cứ cho việc chọn BERT ở tầng 1 (mục 4.2).

2.3 Nhánh gazetteer có chiều thời gian

Khảo sát về gazetteer số nêu yêu cầu ghi nhận tính thời gian trong mọi thành phần: mỗi tên gọi, kiểu thực thể, phạm vi không gian, quan hệ và thuộc tính đều gắn khoảng thời gian hiệu lực, kèm nhãn hiện hành, đã cũ, hoặc dự kiến. Khó khăn cốt lõi mà nhánh này nêu ra là rất khó xác định thời điểm một địa danh bắt đầu hoặc ngừng được gọi bằng một tên, và ngay cả mốc thời gian mơ hồ cũng khó tìm.

Bối cảnh Việt Nam 2025 không có khó khăn đó, vì thay đổi được quy định bằng văn bản pháp quy với ngày hiệu lực chính xác và bảng ánh xạ chính thức. Đây là điều kiện thí nghiệm mà nghiên cứu gazetteer lịch sử không có được: thay vì phải đoán mốc thời gian như nghiên cứu nước ngoài, đề tài có sẵn mốc pháp lý chính xác tuyệt đối.

Hạn chế của nhánh này: cung cấp mô hình dữ liệu tốt nhưng không cung cấp phương pháp học máy.

2.4 Nhánh liên kết bản ghi theo thời gian

Khác với record linkage truyền thống vốn coi khác biệt giữa các bản ghi cùng thực thể là lỗi hoặc biến thể, temporal record linkage nhằm vào các thực thể có giá trị thuộc tính thay đổi theo thời gian. Ba mô hình chính:

- **Time decay** (Li et al., PVLDB 2011): xác suất thực thể đổi giá trị thuộc tính trong một khoảng thời gian. Đáng chú ý, decay học được cho thuộc tính địa chỉ là kết quả chính của bài, trong khi với thuộc tính tên thì decay gần bằng 0.
- **Mutation**: xác suất một giá trị tái xuất hiện theo thời gian.
- **Transition**: xác suất các chuyển đổi giá trị phức tạp theo thời gian.
- **Decay dựa hồi quy** (Hu et al., PAKDD 2017): dùng mô hình hồi quy để dự đoán decay cho từng nhóm thuộc tính.

Hạn chế của nhánh này với bài toán Việt Nam: mọi mô hình trên đều giả định thay đổi diễn ra dần và mang tính ngẫu nhiên, nên xác suất thay đổi là hàm của khoảng thời gian trôi qua. Sáp nhập 2025 là thay đổi gián đoạn, đồng loạt, có ngày hiệu lực xác định. Xác suất không suy giảm dần mà nhảy bậc tại một mốc, nên decay là mô hình sai cho tình huống này.

2.5 Khoảng trống nghiên cứu được xác định

Nhóm dữ liệu và đánh giá (G1, G3, G4)

- **G1 (thiếu dữ liệu).** Khảo sát tài liệu không tìm thấy công trình học thuật nào về parsing hoặc chuẩn hóa địa chỉ tiếng Việt. Các công trình chuẩn hóa văn bản tiếng Việt hiện có (ViLexNorm, ViSoLex) nhằm vào từ vựng mạng xã hội. Chưa có bất kỳ bộ dữ liệu benchmark tiêu chuẩn nào.
- **G3 (kiểu lỗi chưa được đo).** Trường hợp một đơn vị hành chính ánh xạ tới nhiều đơn vị ở hệ còn lại hiện được giải bằng heuristic mặc định, theo cả hai chiều. Chưa ai đo tỷ lệ lỗi, và đây chính là nguồn của lỗi im lặng.
- **G4 (kiểu lỗi chưa được đo).** Hiệu năng trên nhóm mốc định vị và đường sá yếu hơn hẳn nhóm đơn vị hành chính, và số mẫu đánh giá cho hai nhóm này cũng ít hơn nhiều lần. Địa chỉ tiếng Việt lại dựa nhiều vào chính hai nhóm yếu nhất.

Nhóm kỹ thuật mô hình hóa (G2)

- **G2.** Cơ chế gazetteer adapter và type adapter của GTBERT-Pointer chưa từng được áp dụng và kiểm chứng trên dữ liệu tiếng Việt.

Khoảng trống giao thoa trọng tâm (G5)

- **G5.** Hai nhánh ở mục 2.3 và 2.4 giải hai nửa của bài toán và không giao nhau: một bên cho mô hình dữ liệu nhưng không có phương pháp học, một bên cho phương pháp học nhưng dùng giả định thay đổi liên tục không phù hợp. Chưa có công trình nào kết nối việc phân loại hệ quy chiếu thời gian với gazetteer đa phiên bản dùng mô hình thay đổi gián đoạn. Đây chính là không gian giải pháp của đề án.

3. Kế hoạch xây dựng dữ liệu

3.1 Schema 11 nhãn đề xuất

SoNha, TenDuong, Ngo/Hem, ToaNha/CanHo, PhuongXa, QuanHuyen (chỉ dùng cho hệ cũ), TinhThanh, MocDinhVi, HuongDi, GhiChu, Khac.

Mỗi span mang thêm một thuộc tính phụ hệ = {cũ, mới, không xác định}, phục vụ trực tiếp cho T1. Schema 11 nhãn này là phiên bản chốt sau buổi báo cáo tiến độ và là đầu vào bắt buộc cho công cụ gán nhãn ở mục 3.4.

3.2 Nguồn và quy mô

Cập nhật sau khảo sát nguồn thực tế. Bộ Viet-Receipt-VQA dẫn xuất từ MC-OCR 2021 gồm 2.436 ảnh hóa đơn, nhưng thu từ một số ít cửa hàng nên trường địa chỉ lặp gần như hoàn toàn. Sau khi lọc trùng chỉ còn khoảng 130 chuỗi địa chỉ duy nhất. Đây là trần của nguồn chứ không phải vấn đề của bộ lọc, nên kế hoạch dữ liệu được điều chỉnh như bảng dưới.

Tập con	Quy mô	Nguồn	Công gán nhãn
Địa chỉ đầy đủ, hệ mới	~1.000	OpenStreetMap Việt Nam, snapshot hiện hành (trích Geofabrik, lọc tag addr:*)	Thấp, trường đã tách sẵn trong tag
Địa chỉ thật, bản, hệ cũ (test set nhiều thật)	~130	Viet-Receipt-VQA trên HuggingFace. Toàn bộ số chuỗi duy nhất còn lại sau khi lọc trùng	Cao, nhưng quy mô nhỏ nên chi phí thấp
Địa chỉ thật, hệ cũ (tập chính)	~1.500	OSM full-history snapshot cắt trước 01/07/2025; danh bạ cơ sở công lập (trường học, bệnh viện, bưu cục, chi nhánh ngân hàng); cổng thông tin đăng ký doanh nghiệp	Trung bình, một phần trường đã tách sẵn
Địa chỉ thiếu trường	~800	Sinh từ các tập trên bằng cách xóa trường có kiểm soát	Không, sinh tự động
Địa chỉ mô tả bằng mốc	~500	Tin rao bất động sản và tin tuyển dụng công khai, kết hợp elicitation quy mô nhỏ và sinh tổng hợp có rà soát tay	Trung bình
Địa chỉ lai	~600	Sinh từ cặp ảnh xạ cũ/mới bằng cách trộn thành phần theo tỷ lệ kiểm soát	Không, sinh tự động
Cặp ảnh xạ hai chiều	~600	Diff tag addr:* của cùng một node OSM giữa snapshot trước và sau 01/07/2025, đối chiếu với gazetteer	Thấp, dẫn xuất từ diff và bảng chính thức

Tập con	Quy mô	Nguồn	Công gán nhãn
		hai phiên bản; chia đều A (một cũ sang nhiều mới) và B (một mới sang nhiều cũ)	

Tổng: khoảng 5.100 mẫu, giữ nguyên quy mô so với kế hoạch ban đầu nhưng tỷ lệ dữ liệu thật lại tăng, vì tập cặp ánh xạ hai chiều chuyển từ sinh tổng hợp sang trích từ diff OSM thật. Con số này tham chiếu quy mô thực tế trong tài liệu: LGL dùng 5.088 toponym, corpus huấn luyện của Hu et al. tổng cộng 4.291 ví dụ, CADD có 8,96k câu.

Vai trò mới của tập hóa đơn. 130 chuỗi không đủ làm tập huấn luyện, nhưng đủ để làm hai việc có giá trị hơn. Thứ nhất, làm test set nhiều thật: mô hình huấn luyện trên dữ liệu có nhiều sinh tổng hợp, đánh giá trên tập này, và báo cáo khoảng cách synthetic-to-real (thí nghiệm E4). Thứ hai, làm cơ sở ước lượng phân bố nhiễu: thống kê tần suất viết tắt (P., Q., TP., đ/c), tỷ lệ thiếu từng trường, kiểu lỗi chính tả và lỗi OCR, từ đó tham số hóa script sinh nhiễu thay vì giả định phân bố. Quy mô nhỏ vẫn chấp nhận được vì các benchmark tham chiếu trong lĩnh vực cũng ở cỡ vài nghìn, và WOTR còn nhỏ hơn.

OSM full-history. Geofabrik cung cấp file vietnam-internal.osh.pbf chứa toàn bộ lịch sử chỉnh sửa, mở miễn phí cho tài khoản OpenStreetMap, giấy phép ODbL. Dùng osmium time-filter cắt một snapshot trước ngày hiệu lực 01/07/2025 rồi lọc tag addr:* sẽ thu được địa chỉ viết theo hệ cũ. Quan trọng hơn, so tag của cùng một node giữa snapshot cũ và snapshot hiện hành cho ra cặp ánh xạ cũ và mới do chính người dùng cập nhật, tức dữ liệu thật thay vì dẫn xuất từ bảng.

Nguồn đã cân nhắc và loại: OpenAddresses bị loại vì coverage tập trung ở Mỹ, Canada, Úc và một phần châu Âu, gần như không có dữ liệu đáng kể cho Việt Nam. Danh bạ cơ sở công lập trước đây xếp là nguồn dự phòng, nay nâng lên nguồn chính vì mức độ nhiễu nằm giữa hóa đơn và OSM, đúng dài cần thiết.

Elicitation quy mô nhỏ: khảo sát khoảng 40 sinh viên, mỗi người nhập 5 địa chỉ địa điểm công cộng (quán quen, trường cũ, chỗ làm thêm) theo đúng cách họ thường gõ khi đặt hàng, thu được khoảng 200 mẫu do người thật viết. Không thu địa chỉ nhà riêng để tránh vấn đề dữ liệu cá nhân.

Lưu ý giấy phép: Viet-Receipt-VQA dẫn xuất từ MC-OCR nên nhiều khả năng ràng buộc phi thương mại. Cần kiểm tra trước khi công bố.

3.3 Gazetteer đa phiên bản

Đây là thay đổi quan trọng so với thiết kế ban đầu. Thay vì một gazetteer phẳng, đề tài xây dựng gazetteer có phiên bản, theo mô hình dữ liệu của nhánh gazetteer thời gian.

Mỗi bản ghi mang các trường: tên chuẩn, danh sách tên thay thế và viết tắt, cấp hành chính, đơn vị cha, khoảng thời gian hiệu lực, nhãn trạng thái (hiện hành hoặc đã cũ), và các liên kết ánh xạ sang phiên bản còn lại (quan hệ nhiều nhiều).

Nguồn:

- Danh mục đơn vị hành chính trước 2025 và hiện hành (vietnamadminunits, vn-xaphuong-2025).
- GeoNames bản trích Việt Nam cho tọa độ và tên thay thế.
- OSM full-history (vietnam-internal.osh.pbf) cắt theo hai mốc thời gian, dùng để đối chiếu và bổ sung liên kết ánh xạ giữa hai phiên bản.
- Wikipedia tiếng Việt cho corpus embedding tên địa danh, theo quy trình của GTBERT-Pointer.
- Bảng ánh xạ tên gọi và viết tắt xây bằng biểu thức chính quy.

3.4 Quy trình và công cụ gán nhãn

Công cụ: Label Studio, cấu hình sẵn schema 11 nhãn cùng thuộc tính phụ hệ. Toàn bộ phần gán tay (tập hóa đơn và tập mốc định vị) chạy qua công cụ này để có định dạng xuất thống nhất và log thời gian gán nhãn.

Quy trình: gán nhãn hai vòng, đo độ đồng thuận trên 10% mẫu chồng lấn bằng Cohen's Kappa. Với phần sinh tổng hợp, rà soát và chỉnh tay từng mẫu.

Xử lý trùng lặp: chỉ lọc trùng ở mức chuỗi chính xác, không lọc trùng theo địa chỉ đã chuẩn hóa. Lý do: hai surface form khác nhau của cùng một địa chỉ (viết tắt khác nhau, lỗi OCR khác nhau) là hai mẫu khác nhau đối với parser. Ràng buộc bắt buộc đi kèm là chia train/test theo group, mỗi địa chỉ chuẩn hóa là một group, để tránh rò rỉ dữ liệu giữa hai tập.

Cân nhắc đạo đức và pháp lý: không dùng dữ liệu địa chỉ thật của khách hàng. Toàn bộ lấy từ nguồn mở, nguồn công bố công khai, hoặc sinh tổng hợp. Với các cổng thông tin doanh nghiệp và trang rao vặt, cần đọc điều khoản sử dụng trước khi thu thập và trước khi công bố bộ dữ liệu.

4. Phương pháp đề xuất

4.1 Kiến trúc hai tầng

Bước	Nội dung
Đầu vào	Chuỗi địa chỉ tiếng Việt tự do
Tiền xử lý tiếng Việt	Giữ dấu phẩy làm ranh giới trường, cân nhắc giữ chữ hoa (xem thí nghiệm E1)
TẦNG 1: parsing và phân loại hệ quy chiếu	PhoBERT + gazetteer adapter (đa phiên bản) + type adapter. Decoder A: efficient global pointer, sinh span có nhãn (T0). Decoder B: đầu phân loại 3 lớp, sinh hệ = cũ / mới / lai (T1).
Định tuyến	Nếu chuỗi nhất quán và không mơ hồ: đi thẳng tra bảng ánh xạ (T2). Nếu độ tin cậy thấp, có nhãn MocDinhVi, ánh xạ một-nhiều, hoặc hệ = lai: chuyển xuống tầng 2.
TẦNG 2: phân giải	LLM 7B + LoRA, ngữ cảnh RAG là danh sách ứng viên từ gazetteer, kèm thông tin phiên bản và khoảng hiệu lực của từng ứng viên. Sinh ra tham chiếu hành chính đầy đủ, KHÔNG sinh tọa độ.
Chuỗi geocoder	Nominatim, sau đó GeoNames, sau đó fallback
Đầu ra	Mã đơn vị hành chính ở cả hai hệ, kèm tọa độ

4.2 Các quyết định thiết kế và căn cứ

Quyết định	Căn cứ
T1 là đầu phân loại riêng, chia sẻ encoder với T0	Hai tác vụ dùng chung tín hiệu (sự hiện diện của cấp quận huyện, tên phường thuộc phiên bản nào), nên học đa nhiệm rẻ hơn hai mô hình riêng
Gazetteer mang phiên bản chứ không ghi đề	Cơ chế cập nhật động của GTBERT-Pointer chỉ làm mới dữ liệu nên không phân biệt được hệ; mô hình dữ liệu có khoảng hiệu lực là chuẩn của nhánh gazetteer thời gian
Không dùng decay model cho T2 và T3	Decay giả định thay đổi liên tục và ngẫu nhiên; thay đổi 2025 là gián đoạn có ngày hiệu lực. Dùng ánh xạ tất định cộng phân giải ngữ cảnh thay vì mô hình xác suất theo thời gian

Quyết định	Căn cứ
Dùng BERT chứ không dùng LLM ở tầng 1	LLM zero-shot trên parsing địa chỉ có hallucination đáng kể, gồm sinh nhân không có trong đầu vào; phương pháp prompting dùng GPT-3 vẫn thua mô hình nền BERT
Chèn adapter sau lớp 1, chỉ một adapter	Bảng khảo sát siêu tham số của GTBERT-Pointer: lớp 1 đạt F1 92,77; lớp 6 còn 85,76; lớp 12 còn 46,42; chèn nhiều adapter sập xuống dưới 1
LLM không sinh tọa độ	Hai nhóm độc lập cùng kết luận: thử sinh tọa độ trực tiếp cho kết quả không ổn định; sai số suy luận dưới 35km so với sai số tri thức trên 200km
Cấp ứng viên từ gazetteer làm ngữ cảnh	Tăng từ 0,90 lên 0,93 nhờ Top-17 ứng viên; đồng thời khắc phục kiểu lỗi bịa tham chiếu
Xâu chuỗi nhiều geocoder	GeoNames đơn lẻ 0,65, ArcGIS 0,89, khâu chuỗi ba dịch vụ 0,91
Không dùng dân số để xếp hạng ứng viên	Dân số các đơn vị mới chưa ổn định; phương pháp dựa dân số tụt dưới 0,25 trên tập nhiều mơ hồ

5. Kế hoạch thực nghiệm

5.1 Hệ baseline

Baseline	Thế hệ	Ghi chú
vietnamadminunits	Dựa luật	Baseline thực tế đang dùng trong ngành; chỉ hỗ trợ chiều cũ sang mới
Libpostal	CRF	Không fine-tune được, dùng để so trần tốc độ
Deepparse zero-shot	LSTM	Đo mức tổng quát hóa sang tiếng Việt
Deepparse fine-tuned (BPEmbAttention)	LSTM	BPEmb tổng quát hóa tốt hơn sang ngôn ngữ chưa thấy, và chỉ tốn ~1GB RAM so với ~8GB của fastText
PhoBERT + CRF	Transformer	Baseline Transformer chuẩn
Khớp chuỗi trên gazetteer đơn phiên bản	Dựa luật	Baseline riêng cho T1, để đo mức lỗi im lặng ở tình huống D
Mô hình đề xuất	Transformer + adapter đa phiên bản	Tầng 1 hoàn chỉnh trong ĐACN, tầng 2 ở ĐATN

5.2 Năm giả thuyết cần kiểm chứng

H1. Type adapter quan trọng với tiếng Việt hơn với tiếng Trung.

Nghiên cứu gốc thấy type adapter đóng góp rất nhỏ và giải thích rằng gazetteer đã chứa sẵn hầu hết đơn vị hành chính. Lập luận đó dựa trên hệ hành chính ổn định. Ở Việt Nam gazetteer đang lệch còn cây phân cấp mới thì có sẵn dạng chính thức, nên dự đoán chiều ngược lại. Thí nghiệm: ablation gỡ từng adapter.

H2. Huấn luyện có kèm địa chỉ thiếu trường phục hồi được hiệu năng.

Tái lập phát hiện của Yassine et al. cho tiếng Việt: hiệu năng tụt 20 đến 40% trên địa chỉ thiếu trường, và phục hồi lên trên 98% khi đưa dữ liệu thiếu vào huấn luyện.

H3. Mô hình học thuộc mẫu chứ không học cấu trúc.

Tiếng Việt viết địa chỉ từ lớn xuống nhỏ, giống tiếng Hàn. Yassine et al. phát hiện mô hình đạt 100% trên tiếng Hàn nhưng khi xáo lại thứ tự thì rơi xuống 28,04%, trong khi gán nhãn ngẫu nhiên đã cho 12,29%. Thí nghiệm: xáo thứ tự trường trên tập test tiếng Việt.

H4. Hiệu năng trên nhóm mốc và đường sá thấp hơn rõ rệt so với đơn vị hành chính.

Báo cáo kết quả tách riêng theo bốn nhóm loại địa điểm.

H5. Địa chỉ lai là lớp khó nhất, và mô hình có nhận biết phiên bản vượt trội rõ rệt ở lớp này.

Dự đoán: baseline tra bảng gần như thất bại hoàn toàn trên tập lai vì chuỗi không nhất quán nội tại. Thí nghiệm: báo cáo hiệu năng T1 và T2 tách theo từng tình huống A, B, C, D. Đặc biệt đo tỷ lệ lỗi im lặng ở tình huống D, tức tỷ lệ hệ thống trả về kết quả sai mà không có tín hiệu cảnh báo.

5.3 Thí nghiệm phụ (chi phí thấp)

E1. Tiền xử lý. Deepparse mặc định hạ chữ thường và xóa toàn bộ dấu phẩy. Địa chỉ tiếng Việt dùng dấu phẩy làm ranh giới trường rất nhất quán, và tên riêng viết hoa cũng là tín hiệu. Thí nghiệm bốn cấu hình: giữ/bỏ dấu phẩy nhân giữ/bỏ chữ hoa.

E2. Ánh xạ một-nhiều hai chiều. Đo tỷ lệ lỗi của heuristic mặc định hiện hành so với mô hình có dùng thông tin tên đường, ở cả chiều A và chiều B.

E3. Tính bất đối xứng của hai chiều ánh xạ. Chiều cũ sang mới và chiều mới sang cũ có độ khó ngang nhau không? Giả thuyết: chiều B khó hơn vì đơn vị mới thường gộp từ nhiều đơn vị cũ với số lượng lớn hơn, nên không gian ứng viên rộng hơn.

E4. Khoảng cách synthetic-to-real. Huấn luyện trên dữ liệu có nhiều sinh tổng hợp, đánh giá song song trên tập test sinh tổng hợp và trên 130 chuỗi hóa đơn nhiều thật. Báo cáo mức chênh lệch giữa hai tập. So sánh thêm hai cấu hình sinh nhiều: phân bố giả định và phân bố ước lượng từ chính 130 mẫu thật, để đo giá trị của việc hiệu chỉnh noise model theo dữ liệu thật.

5.4 Metric

Nhóm	Metric
T0 parsing	Accuracy theo token; Exact match toàn địa chỉ; F1 theo từng trường
T1 phân loại hệ	Macro-F1 ba lớp; ma trận nhầm lẫn
T2 ánh xạ	Accuracy ánh xạ đơn vị hành chính, tách theo chiều; Accuracy@161km cho tọa độ; tỷ lệ lỗi im lặng
Vận hành	Latency mỗi địa chỉ; bộ nhớ GPU đỉnh
Tổng quát hóa	Chênh lệch exact match giữa tập test sinh tổng hợp và tập test nhiều thật (E4)

Lưu ý về metric: con số 99% của Deepparse tính theo tỷ lệ nhãn đúng trong chuỗi, còn 99,45% của Libpostal tính theo toàn chuỗi. Hai metric không so trực tiếp được. Với ứng dụng giao hàng thì exact match mới có ý nghĩa thực tế, vì sai một trường là giao sai.

6. Phân chia công việc giữa ĐACN và ĐATN

Hạng mục	Đồ án chuyên ngành (học kỳ này)	Đồ án tốt nghiệp (học kỳ sau)
Dữ liệu	Xây xong bộ benchmark và gazetteer đa phiên bản	Mở rộng quy mô, bổ sung tập ngoài miền

Hạng mục	Đồ án chuyên ngành (học kỳ này)	Đồ án tốt nghiệp (học kỳ sau)
T0 parsing	Baseline đầy đủ	Mô hình đề xuất với hai adapter
T1 phân loại hệ	Hiện thực đầu phân loại, đo trên tập lai	Tinh chỉnh, phân loại ở cấp trường
T2 ánh xạ	Baseline tra bảng hai chiều, đo tỷ lệ lỗi	Mô hình phân giải dùng ngữ cảnh
T3 đối sánh qua thời gian	Chỉ thiết kế và đặc tả	Hiện thực đầy đủ
Tầng 2 LLM	Chưa hiện thực	Hiện thực LLM + RAG + chuỗi geocoder
Thực nghiệm	H2, H3, H5, E1, E3	H1, H4, E2
Hệ thống	Bản demo tối thiểu	API FastAPI, đóng gói Docker
Đầu ra	Đề cương + bộ dữ liệu + bảng baseline + phân tích lỗi	Bài báo hội nghị trong nước hoặc workshop

Ghi chú về lựa chọn thí nghiệm cho học kỳ này: H2, H3, H5, E1, E3 đều là tái lập phát hiện đã có trên ngữ cảnh mới hoặc so sánh baseline, nên gần như chắc chắn ra kết quả. Các thí nghiệm phụ thuộc vào việc mô hình đề xuất phải bằng phẳng đều nằm ở học kỳ sau.

7. Lộ trình

7.1 Kế hoạch chi tiết hai tuần tới

Mục này là phần cam kết ngắn hạn đã trình bày trong buổi báo cáo tiến độ, gồm hai luồng chạy song song.

Luồng 1. Phát triển và gán nhãn bộ dữ liệu benchmark

Mục tiêu: xây dựng hoàn chỉnh 5 tập dữ liệu cốt lõi bằng cả phương pháp tự động (viết code) và thủ công (gán nhãn).

- **Xử lý bằng code (tự động hóa):** viết Python script sinh ra ~800 mẫu thiếu trường (chủ động xóa quận/phường), ~600 mẫu địa chỉ lai (trộn cũ và mới có kiểm soát) và ~600 cặp ánh xạ hai chiều (dựa trên bảng từ điển sáp nhập).
- **Xử lý thủ công và bán thủ công (Label Studio):** đẩy toàn bộ ~130 chuỗi hóa đơn duy nhất còn lại (Viet-Receipt-VQA) và mở đầu của tập hệ cũ trích từ OSM full-history lên công cụ để gán nhãn tay từng thành phần. Đồng thời thu thập và rà soát bằng mắt ~500 mẫu định vị bằng mốc.

Luồng 2. Thực nghiệm baseline và chốt lý thuyết

Mục tiêu: đóng gói chương Động lực nghiên cứu (Chương 1) và Cơ sở lý thuyết (Chương 2).

- **Đánh giá baseline:** chạy mẫu thô qua vietnamadminunits và Libpostal, lập bảng ghi nhận các ca lỗi thực tế phủ đủ 4 tình huống mơ hồ (A, B, C, D) để làm bằng chứng bảo vệ đề tài.
- **Chốt kiến trúc:** khớp nối kết quả khảo sát từ 3 nhánh nghiên cứu để chốt dứt điểm schema 11 nhân và cấu trúc dữ liệu cho gazetteer đa phiên bản.

Luồng 3. Bù nguồn dữ liệu hệ cũ (phát sinh sau khảo sát nguồn)

Mục tiêu: xác nhận nguồn thay thế cho phần địa chỉ hệ cũ sau khi Viet-Receipt-VQA chỉ còn ~130 chuỗi duy nhất.

- Đăng nhập tài khoản OSM, tải vietnam-internal.osh.pbf, chạy osmium time-filter ở mốc 30/06/2025, đếm số node có addr:street và addr:city. Nếu vượt 1.000 thì coi như vấn đề nguồn đã được giải quyết.
- Chạy thống kê phân bố nhiều trên 130 mẫu thật (tần suất viết tắt, tỷ lệ thiếu từng trường, kiểu lỗi OCR) để lấy tham số cho script sinh nhiễu.
- Đọc điều khoản sử dụng của cổng thông tin đăng ký doanh nghiệp và các trang rao vặt trước khi thu thập.

Sản phẩm bàn giao cuối hai tuần: (1) ba tập sinh tự động đã có file; (2) dự án Label Studio đã cấu hình schema và nạp xong tập hóa đơn cùng mè đầu của tập hệ cũ; (3) bảng phân loại lỗi baseline theo bốn tình huống; (4) bản đặc tả schema và gazetteer đã chốt; (5) báo cáo ngắn về số lượng mẫu thu được từ OSM full-history và bảng thống kê phân bố nhiễu.

7.2 Lộ trình 15 tuần

Tuần	Công việc	Sản phẩm
1-2	Khảo sát tài liệu ba nhánh, chốt schema nhãn và mô hình gazetteer đa phiên bản	Chương 1-2 của báo cáo
3	Chạy vietnamadminunits và Libpostal trên mẫu thô, ghi lại các ca sai theo bốn tình huống A đến D	Bảng phân loại lỗi thực tế, dùng làm motivation
4-5	Trích tập hệ cũ từ OSM full-history, danh bạ công lập và đăng ký doanh nghiệp (~1.500); gán nhãn tập này cùng 130 chuỗi hóa đơn trên Label Studio	Tập hệ cũ và test set nhiễu thật
6	Trích và gán nhãn tập OSM (~1.000, hệ mới, gần như tự động)	Tập đối chứng sạch
7	Dựng gazetteer đa phiên bản; sinh tập thiếu trường, tập lai, tập cặp ánh xạ hai chiều	Bộ dữ liệu đủ sáu lớp con
8	Đo độ đồng thuận gán nhãn; chốt tập test	Chỉ số Cohen's Kappa, tập test đóng băng
9-10	Fine-tune Deepparse với schema mới; chạy PhoBERT-CRF; hiện thực đầu phân loại T1	Bảng baseline đầy đủ
11	Thí nghiệm H2 và H3	Hai bảng kết quả
12	Thí nghiệm H5 và E3, tách theo bốn tình huống	Bảng kết quả theo tình huống, số liệu lỗi im lặng
13	Thí nghiệm E1; phân tích lỗi định tính; đặc tả tầng 2 và T3	Chương phân tích và đặc tả kiến trúc
14	Demo tối thiểu; viết báo cáo	Bản nháp đầy đủ
15	Hoàn thiện, chuẩn bị bảo vệ	Báo cáo cuối, slide

Mốc kiểm tra tuần 3: nếu chưa chạy được baseline dựa luật và chưa có ví dụ lỗi cụ thể, cần báo GVHD để điều chỉnh phạm vi ngày, không chờ tới tuần 8.

8. Tài nguyên

Hạng mục	Ước lượng	Căn cứ
GPU cho tầng 1	8 đến 16GB VRAM	GTBERT-Pointer chạy trên V100 16GB, đỉnh 8 đến 16GB
GPU cho tầng 2 (học kỳ sau)	14GB cho mô hình 7B với LoRA	Hu et al. báo cáo đúng con số này
RAM	~1GB nếu dùng BPEmb, ~8GB nếu dùng fastText	Bảng đo của Deepparse
Lưu trữ	Dưới 10GB	Corpus gazetteer và dữ liệu văn bản
Chi phí API	Gần bằng không	Tự host Nominatim; tránh Google Maps API vì hạn mức miễn phí 40.000 request mỗi tháng trị giá 200 USD

Kết luận: Colab free hoặc Kaggle đủ cho toàn bộ phần ĐACN.

9. Rủi ro và phương án dự phòng

Rủi ro	Mức	Phương án
Nguồn hóa đơn cạn (đã xảy ra): Viet-Receipt-VQA chỉ còn ~130 chuỗi duy nhất	Đã hiện thực hóa	Chuyển 130 mẫu sang vai trò test set nhiều thật và cơ sở ước lượng phân bố nhiều; bù khối lượng bằng OSM full-history, danh bạ công lập và đăng ký doanh nghiệp
OSM full-history có quá ít node mang tag addr:* ở snapshot cũ	Trung bình	Kiểm tra ngay trong hai tuần đầu. Nếu dưới ngưỡng, dồn sang danh bạ công lập và tăng tỷ trọng sinh nhiều có hiệu chỉnh
Điều khoản sử dụng của nguồn doanh nghiệp và rao vặt hạn chế thu thập hoặc công bố	Trung bình	Đọc điều khoản trước khi crawl; nếu vướng thì chỉ dùng nội bộ để huấn luyện và công bố phần dẫn xuất không tái tạo được nguồn
Giấy phép Viet-Receipt-VQA hạn chế công bố	Trung bình	Kiểm tra ngay tuần 1; quy mô 130 mẫu nhỏ nên có thể thay bằng tập tự thu nếu cần
Kết quả H1 ra âm	Trung bình	Kết quả âm vẫn là đóng góp hợp lệ. Cần thống nhất trước với GVHD rằng null result được chấp nhận
Gazetteer sau sáp nhập còn cập nhật tiếp	Trung bình	Đóng băng phiên bản gazetteer và ghi rõ ngày chốt trong báo cáo
Tập lai sinh tổng hợp không giống phân bố thật	Trung bình	Đối chiếu với mẫu lai thật thu được từ nguồn công khai; báo cáo rõ đây là dữ liệu sinh
Code GTBERT-Pointer không public	Trung bình	Tự hiện thực lại adapter theo mô tả; khối lượng này đã tính vào ĐATN

10. Tài liệu tham khảo chính

Phân tích và phân giải địa chỉ

1. Huang, J., Liu, S., Qiao, Y., Wu, Y. (2025). Gazetteer- and type-enhanced Chinese address parsing BERT with an efficient global pointer. International Journal of Digital Earth, 18(2).

2. Beauchemin, D., Yassine, M. (2023). Deepparse: An Extendable, and Fine-Tunable State-Of-The-Art Library for Parsing Multinational Street Addresses. arXiv:2311.11846.
3. Yassine, M., Beauchemin, D., Laviolette, F., Lamontagne, L. (2021). Multinational Address Parsing: A Zero-Shot Evaluation. arXiv:2112.04008.
4. Yassine, M., et al. (2020). Leveraging Subword Embeddings for Multinational Address Parsing. IEEE CiSt.

Phân giải địa danh và mã hóa địa lý

5. Hu, X., Kersten, J., Klan, F., Farzana, S. M. (2026). Toponym resolution leveraging lightweight and open-source large language models and geo-knowledge. IJGIS, 40(3).
6. Hu, X., Kersten, J., Klan, F. (2025). Scalable Toponym Resolution with LLMs. GeoExT 2025.
7. Masis, T., O'Connor, B. (2026). Coordinates from Context: Using LLMs to Ground Complex Location References. arXiv:2510.08741.
8. Zhang, Z., Bethard, S. (2024). A survey on geocoding: algorithms and datasets for toponym resolution. LRE.

Gazetteer có chiều thời gian

9. Digital Gazetteers: Review and Prospects for Place Name Knowledge Bases. ACM Computing Surveys, 2025. arXiv:2507.08553.
10. Southall, H., Mostern, R., Berman, M. L. (2011). On historical gazetteers. International Journal of Humanities and Arts Computing, 5(2).

Liên kết bản ghi theo thời gian

11. Li, P., Dong, X. L., Maurino, A., Srivastava, D. (2011). Linking Temporal Records. PVLDB, 4(11), 956-967.
12. Hu, Y., Wang, Q., Vatsalan, D., Christen, P. (2017). Improving Temporal Record Linkage Using Regression Classification. PAKDD.

Tài nguyên phần mềm và dữ liệu:

- github.com/GRAAL-Research/deepparse và [deepparse-address-data](https://github.com/GRAAL-Research/deepparse-address-data)
- github.com/uhuohuy/LLM-geocoding
- github.com/tranngocminhhieu/vietnamadminunits
- github.com/phucanhle/vn-xaphuong-2025
- huggingface.co/datasets/5CD-AI/Viet-Receipt-VQA
- CADD: github.com/leodotnet/neural-chinese-address-parsing
- Label Studio (labelstud.io) cho quy trình gán nhãn span
- osmium-tool cho thao tác time-filter trên file OSM full-history
- osm-internal.download.geofabrik.de cho file [vietnam-internal.osh.pbf](https://osm-internal.download.geofabrik.de/vietnam-internal.osh.pbf) (yêu cầu tài khoản OpenStreetMap)

Phụ lục: các điểm cần xác nhận với GVHD

1. Trọng số chấm điểm cho nhóm 2 thành viên trong CO4029 và cách phân chia phần đánh giá cá nhân.
2. Đề tài có được GVHD đồng ý cho tiếp tục lên Đồ án tốt nghiệp không.
3. Kết quả thực nghiệm âm (null result), cụ thể là H1, có được chấp nhận trong báo cáo không.

4. Tên đề tài tiếng Anh: bản đăng ký có cụm "Version-Aware" còn slide báo cáo tiến độ không có. Cần thống nhất một bản duy nhất trước khi in báo cáo.
5. Xin Thầy cho ý kiến về việc điều chỉnh nguồn dữ liệu ở mục 3.2: chuyển 130 chuỗi hóa đơn còn lại sang vai trò test set nhiều thật, và bù khối lượng bằng OSM full-history cùng danh bạ cơ sở công lập.