



# Vietnamese Address Parsing and Resolution across an Administrative Temporal Boundary: A Benchmark Dataset and a Two-Stage Model

**Supervisor:** Quan Thanh Tho

**Student:** Nguyen Quang Tung - 2313817

**Student:** Nguyen Quang Huy - 2311202

Faculty of Computer Science & Engineering  
Ho Chi Minh City University of Technology, Vietnam National University Ho Chi Minh City

**September 21, 2026**

# Table of Contents

- 1 Introduction**
- 2 Preliminaries and Problem Statement**
- 3 Related Works**
- 4 Proposed Method**
- 5 Experiments and Results**
- 6 Conclusion**



## Sự mơ hồ không gian - thời gian trong địa chỉ Việt Nam

- **Đặc thù dữ liệu thực tế:** Địa chỉ Việt Nam thường xuyên thiếu trường, viết tắt tùy tiện và định vị bằng “mốc” thay vì địa danh chuẩn (VD: “đối diện chợ Bà Chiểu”).
- **Cú sốc cải cách hành chính 2025:** Rút gọn còn 34 tỉnh, xóa bỏ cấp huyện và sáp nhập diện rộng tạo ra sự tồn tại song song của hai hệ quy chiếu.

### 4 tình huống mơ hồ cốt lõi:

- **(A) Cũ sang Mới**
- **(B) Mới về Cũ:** Khó khăn trong chuyển đổi và tra cứu ngược hồ sơ.
- **(C) Địa chỉ lai:** Trộn lẫn thành phần cũ - mới trong cùng một câu.
- **(D) Trùng lặp danh pháp:** Tên giống nhau nhưng phạm vi đã thay đổi.

# Bài toán, Mục tiêu & Phạm vi nghiên cứu

- **Bài toán (Đầu vào - Đầu ra):** Từ chuỗi địa chỉ tiếng Việt tự do, hệ thống thực hiện 4 tác vụ: Bóc tách thực thể (T0), Phân loại hệ quy chiếu (T1), Ánh xạ hai chiều (T2), và Đối sánh thực thể qua thời gian (T3).
- **Mục tiêu nghiên cứu cốt lõi:** Xây dựng bộ dữ liệu benchmark và Gazetteer đa phiên bản. Đề xuất mô hình hai tầng có khả năng nhận thức chiều thời gian.
- **Phạm vi thực hiện:** Tập trung xử lý văn bản địa chỉ dân dụng/thương mại xoay quanh đợt cải cách 2025. Không bao gồm OCR, định tuyến giao hàng hay dữ liệu cá nhân.
- **Ràng buộc triển khai:** Đảm bảo tính khả thi cao, mô hình có thể huấn luyện và vận hành trên GPU đơn 16GB (Colab/Kaggle) mà không phụ thuộc API trả phí.



# Khảo sát các hướng tiếp cận & Hạn chế

## Nhánh Phân tích địa chỉ (Parsing):

- Các mô hình SOTA (Libpostal, Deepparse, GTBERT, LLM): Chủ yếu tối ưu cho tiếng Anh/Trung, hiệu năng giảm mạnh khi khuyết trường.
- Điểm mù: Hoàn toàn không có khái niệm thời gian ở tầng mô hình. Baseline tiếng Việt hiện tại (vietnamadminunits) chỉ dựa trên luật cứng và không hỗ trợ nội suy hai chiều.

## Nhánh Gazetteer có chiều thời gian:

- Cung cấp mô hình dữ liệu tốt nhưng thiếu phương pháp học máy.
- Lợi thế bối cảnh: Thay vì phải đoán mốc thời gian như nghiên cứu nước ngoài, cải cách 2025 của Việt Nam cung cấp mốc pháp lý chính xác tuyệt đối (điều kiện thí nghiệm lý tưởng).

## Nhánh Liên kết bản ghi theo thời gian (Temporal Record Linkage):

- Điểm mù: Các mô hình kinh điển (Time decay, Mutation) giả định sự thay đổi diễn ra dần dần và ngẫu nhiên. Trong khi đó, sáp nhập 2025 là biến đổi gián đoạn, đồng loạt và nhảy bậc.

# Research Gaps

## Về Dữ liệu & Đánh giá (G1, G3, G4):

- **G1:** Chưa có bộ dữ liệu benchmark địa chỉ dân dụng gắn nhãn hệ quy chiếu thời gian và hỗ trợ cấu trúc phân cấp biến đổi (các nghiên cứu trước như Bui & Tran 2019 chỉ phân tích tĩnh trên hệ cũ).
- **G3, G4:** Chưa đo lường được tỷ lệ lỗi đối với các mốc định vị tự do và các trường hợp 1 đơn vị cũ tách thành N đơn vị mới (gây lỗi im lặng).

## Về Kỹ thuật mô hình hóa (G2):

- Cơ chế linh hoạt như Gazetteer Adapter (của GTBERT) chưa từng được áp dụng và kiểm chứng trên dữ liệu tiếng Việt.

## Khoảng trống giao thoa trọng tâm (G5):

- Chưa có công trình nào kết nối giữa việc phân loại hệ quy chiếu thời gian và gazetteer đa phiên bản sử dụng mô hình thay đổi gián đoạn. Đây chính là không gian giải pháp của đề án.

# Schema nhãn đề xuất

| Tập con                    | Quy mô | Nguồn                                                                                  | Công gán nhãn                      |
|----------------------------|--------|----------------------------------------------------------------------------------------|------------------------------------|
| Địa chỉ đầy đủ, hệ mới     | ~1.000 | OpenStreetMap Việt Nam                                                                 | Thấp, trường đã tách sẵn trong tag |
| Địa chỉ thật, bản, hệ cũ   | ~2.000 | Viet-Receipt-VQA trên Hugging-Face (dẫn xuất từ MC-OCR 2021)                           | Cao                                |
| Địa chỉ thiếu trường       | ~800   | Sinh từ hai tập trên bằng cách xóa trường có kiểm soát                                 | Không, sinh tự động                |
| Địa chỉ mô tả bằng mốc     | ~500   | Thu thập công khai kết hợp sinh tổng hợp có rà soát tay                                | Trung bình                         |
| Địa chỉ lai (mới)          | ~600   | Sinh từ cặp ánh xạ cũ/mới bằng cách trộn thành phần theo tỷ lệ kiểm soát               | Không, sinh tự động                |
| Cặp ánh xạ hai chiều (mới) | ~600   | Đối chiếu gazetteer hai phiên bản; chia đều A (1 cũ sang N mới) và B (1 mới sang N cũ) | Thấp, dẫn xuất từ bảng chính thức  |

# Nhiệm vụ của 2 tuần tiếp

## Phát triển & Gán nhãn Bộ dữ liệu Benchmark

**Mục tiêu:** Xây dựng hoàn chỉnh 5 tập dữ liệu cốt lõi bằng cả phương pháp tự động (viết code) và thủ công (gán nhãn).

- **Xử lý bằng Code (Tự động hóa):** Viết Python script sinh ra ~800 mẫu thiếu trường (chủ động xóa Quận/Phường), ~600 mẫu địa chỉ lai (trộn Cũ - Mới có kiểm soát) và ~600 cặp ánh xạ hai chiều (dựa trên bảng từ điển sáp nhập).
- **Xử lý thủ công/Bán thủ công (Label Studio):** Đẩy ~2.000 mẫu hóa đơn bản hệ cũ (Viet-Receipt) lên công cụ để gán nhãn tay từng thành phần. Đồng thời, thu thập và rà soát bằng mắt ~500 mẫu định vị bằng mốc.

## Thực nghiệm Baseline & Chốt Lý thuyết

**Mục tiêu:** Đóng gói chương Động lực nghiên cứu (Chương 1) và Cơ sở lý thuyết (Chương 2).

- **Đánh giá Baseline:** Chạy mẫu thô qua vietnamadminunits và Libpostal, lập bảng ghi nhận các ca lỗi thực tế phủ đủ 4 tình huống mơ hồ (A, B, C, D) để làm bằng chứng bảo vệ đề tài.
- **Chốt kiến trúc:** Khớp nối kết quả khảo sát từ 3 nhánh nghiên cứu để chốt dứt điểm Schema 11 nhãn và cấu trúc dữ liệu cho Gazetteer đa phiên bản.

# Sprint 2

# Sprint 2: Mục tiêu vs Kết quả Đạt được

## Đối chiếu Trực tiếp với Kế hoạch Cam kết ở Slide 8

### 1. Về Phát triển Dữ liệu Benchmark (Cam kết tự động hóa & lọc dữ liệu):

- **Cam kết ở Slide 8:** Sinh ~800 thiếu trường, ~600 địa chỉ lai, ~600 cặp ảnh xạ; lọc OSM full-history mốc 30/06/2025.
- **Đạt được:** Hoàn thành 100% qua code: đúng **800 mẫu thiếu trường** (Data 04), **600 mẫu địa chỉ lai** (Data 06) và **600 cặp ảnh xạ hai chiều** (Data 07) được đối chiếu thực tế qua OSM diff.
- **Nghiệm thu:** Đóng băng Bộ 6 tập benchmark (5.500 mẫu) kèm mã băm SHA-256 xác thực bất biến trong `run_manifest.json`.

### 2. Về Thực nghiệm Baseline & Đóng gói Lý thuyết:

- **Cam kết ở Slide 8:** Chạy `vietnamadminunits` và `Libpostal`, lập bảng số liệu phủ đủ 4 ca mơ hồ (A, B, C, D).
- **Đạt được:** Chạy **13.000 lượt dự đoán** sơ bộ trên 2 hệ baseline, lưu 100% log phản hồi thô không crash; thu thập đầy đủ bằng chứng định lượng và các ca lỗi thực tế phủ đủ A, B, C, D.
- **Đạt được:** Hoàn thành bản thảo chi tiết **Chương 1** (Động lực) và **Chương 2** (Cơ sở lý thuyết).

# Problem Statement

## Mô hình hóa 4 Tình huống Không gian - Thời gian (A, B, C, D)

- **Tình huống A (Ánh xạ xuôi Cũ → Mới):** Đơn vị hành chính cũ chuyển sang mới theo quan hệ: 1 – 1 (giữ nguyên),  $N - 1$  (hợp nhất),  $1 - N$  (chia tách),  $M - N$  (chia tách và tái cơ cấu phức tạp).
- **Tình huống B (Ánh xạ ngược Mới → Cũ):** Truy xuất lịch sử địa chỉ từ hệ mới phục vụ lưu trữ hồ sơ pháp lý (Bài toán phân rã  $1 \rightarrow N$  bất định nếu thiếu số nhà).
- **Tình huống C (Địa chỉ Lai):** Chuỗi địa chỉ pha trộn: C1 (Phường mới + Huyện cũ + Tỉnh cũ), C2 (Phường mới + Huyện cũ + Tỉnh mới), C3 (Phường cũ + Huyện cũ + Tỉnh mới).
- **Tình huống D (Nhập nhầm Không gian):** Đồng âm tên xã/phường diện rộng, mất neo phân cấp khi bị khuyết quận/huyện hoặc gặp nhiễu OCR.

## Phương pháp Tiếp cận Dựa trên Quy tắc (Rule-based / Gazetteer)

- **Đại diện tiêu biểu:** Thư viện vietnamadminunits (bộ từ điển hành chính kết hợp Trie / Regex).
- **Cơ chế hoạt động:** Tra cứu từ khóa hành chính ngược từ phải sang trái (Tỉnh → Huyện → Xã), bóc tách phần còn lại thành Số nhà và Tên đường.
- **Ưu điểm:**
  - Tốc độ xử lý cực nhanh, bộ nhớ thấp.
  - Độ chính xác tuyệt đối (97,3%) khi chuỗi đầu vào sạch chuẩn, đúng chính tả tiếng Việt.
- **Nhược điểm cốt tử:**
  - Cực kỳ nhạy cảm với lỗi chính tả và nhiễu OCR (tỷ lệ đúng sập đổ xuống 21,7%).
  - Tê liệt trước địa chỉ khuyết thiếu hoặc cấu trúc đảo thứ tự.
  - Dễ gây ra lỗi âm thầm (*Silent Error*) ở quan hệ chia tách  $M - N$  do fallback gán bừa vào xã mặc định.

## Phương pháp Gán nhãn Chuỗi Cổ điển (CRF / Libpostal)


- **Đại diện tiêu biểu:** Thư viện Libpostal (OpenVenues — thư viện C phân tích địa chỉ đa ngôn ngữ hàng đầu thế giới).
- **Cơ chế hoạt động:** Mô hình Trường ngẫu nhiên có điều kiện (CRF) huấn luyện trên hàng triệu địa chỉ OSM toàn cầu.
- **Ưu điểm:**
  - Khả năng chịu lỗi biến thể từ vựng tốt hơn rule-based, tốc độ thực thi rất nhanh.
- **Nhược điểm cốt tử:**
  - Mô hình bị đóng băng trên cấu trúc 3 cấp cũ: Bắt buộc chuỗi phải có cấp Quận/Huyện.
  - Ảo giác Quận nặng nề (77,5%): Khi gặp địa chỉ hệ mới 2 cấp (không có quận), mô hình tự ý xé cụm từ Phường/Xã để gán cho Quận (Exact Match chạm đáy 0,2%).
  - Hoàn toàn thất bại trước địa chỉ lai (0,3% Exact Match).

# Table of Contents

- 1 Introduction
- 2 Preliminaries and Problem Statement
- 3 Related Works
- 4 Proposed Method**
- 5 Experiments and Results
- 6 Conclusion



## Kiến trúc Pipeline Trích xuất Dữ liệu & Tạo Benchmark



# Component 1

## Trích xuất OSM Full-History & Lọc Thời gian Lịch sử

- **Nguồn gốc thô & Mốc lọc:** Tập vietnam-internal.osh.pbf (756.709.921 bytes, SHA-256 xác thực). Dùng pyosmium duyệt mốc cắt lịch sử trước đợt sáp nhập:

$$\text{Timestamp}(v_i) \leq 2025-06-30T23:59:59Z \wedge \text{visible} = \text{True}$$

- **Khối lượng thô ban đầu (trước lọc địa lý):** Trích xuất được tổng cộng **26.961 thực thể** có gắn thẻ địa chỉ addr:\*, gồm **15.749 node** và **11.212 way**.
- **Đo lường chất lượng trên tập 15.749 node thô:**
  - Node sạch hoàn chỉnh (đủ cả 5 trường): **6.008 / 15.749 node** (38,15%).
  - Node thiếu tự nhiên ( $\geq 1$  trường bị khuyết): **9.741 / 15.749 node** (61,85%, chủ yếu thiếu số nhà).
- **Snapshot cân bằng 3 miền (sau lọc địa lý & làm sạch):**
  - Lọc ra tập cân bằng **16.242 bản ghi** (gồm cả node và way: Bắc 61,6%, Nam 30,3%, Trung 8,1%).
  - Trong đó có **8.848 bản ghi sạch hoàn hảo** (đủ 5 trường) được chọn làm nguồn chuẩn để lấy mẫu 1.500 dòng cho Data 03 và tạo Data 04.



# Component 2

## Lập Hồ sơ Nhiễu từ Hóa đơn Thực tế (Viet-Receipt-VQA)

- Khảo sát 1.659 hóa đơn bán lẻ thô → làm sạch và chọn lọc 146 chuỗi địa chỉ giao dịch thực tế.
- Đo lường định lượng các dạng sai lệch văn bản thực tế (`configs/noise_params.json`):

| Dạng nhiễu thực tế     | Tần suất | Biểu hiện cụ thể                                   |
|------------------------|----------|----------------------------------------------------|
| Viết tắt hành chính    | 60,3%    | P., Q., TP., TX., TT., P.Q.                        |
| Bỏ dấu / Lỗi Telex     | 45,5%    | Phuong Ben Nghe, Q.Binh Thanh, Duong               |
| Lỗi OCR ký tự hình học | 9,0%     | Nhầm 0 ↔ O, Đ ↔ D/E, dấu phẩy ↔ chấm               |
| Đảo trật tự phân cấp   | 9,5%     | Đưa Quận lên trước đường, Số nhà đặt ở cuối        |
| Nhiều dấu phân cách    | 100,0%   | Dấu gạch ngang, thiếu khoảng trắng, nhiều dấu phẩy |

- Đóng vai trò làm cơ sở tham số hóa cho generator sinh Data 02 nhiễu tổng hợp có kiểm soát.

# Component 3

## Sinh Dữ liệu Benchmark Chuyên đề Có kiểm soát (Data 04, 06, 07)

- **Data 04 — Thiếu trường có kiểm soát ( $N = 800$ ):**

- Sinh từ nguồn sạch (400 cũ, 400 mới) rồi chủ động lược bỏ: khuyết số nhà (348), khuyết phường (241), khuyết cả số nhà và phường (112), khuyết quận (99).
- Bảo toàn 100% các trường  $GT\_*$  gốc để phục vụ đo lường khả năng phục hồi thông tin.

- **Data 06 — Địa chỉ lai ( $N = 600$ ):**

- Sinh theo 3 mô hình dịch chuyển: C1 (420 mẫu: Phường mới + Huyện cũ + Tỉnh cũ); C2 (120 mẫu: Phường mới + Huyện cũ + Tỉnh mới); C3 (60 mẫu: Phường cũ + Huyện cũ + Tỉnh mới).
- Toàn bộ 600 chuỗi duy nhất 100%, khớp đúng các cạnh trong bảng sáp nhập chuẩn.

- **Data 07 — Cặp ánh xạ hai chiều ( $N = 600$  cặp):**

- Kiểm toán 1.631 OSM diffs → lọc đúng 600 cặp quan sát thực tế (356 cặp  $M - N$ , 244 cặp  $N - 1$ ). Số nhà và tên đường giữ nguyên vẹn qua hai thời kỳ.

# Table of Contents

- 1 Introduction
- 2 Preliminaries and Problem Statement
- 3 Related Works
- 4 Proposed Method
- 5 Experiments and Results**
- 6 Conclusion



## Bộ 6 Tập Benchmark Đóng băng (v2.0 — SHA-256 Verified)

| Tập     | Tên tập benchmark                   | Số mẫu | Hệ quy chiếu | Đặc trưng kỹ thuật cốt lõi                 |
|---------|-------------------------------------|--------|--------------|--------------------------------------------|
| Data 01 | 01_full_address_new_verified.csv    | 1.000  | mọi          | Mô hình 2 cấp tinh gọn, Quan-Huyen rỗng    |
| Data 02 | 02_raw_noisy_synthetic_1000.csv     | 1.000  | cu & mọi     | Nhiều tổng hợp thực tế, giữ 100% GT_*      |
| Data 03 | 03_real_address_old_1500.csv        | 1.500  | cu           | Chuẩn sạch hoàn toàn, đủ cả 5 trường       |
| Data 04 | 04_missing_fields_800.csv           | 800    | cu & mọi     | Khuyết trường có kiểm soát, bảo toàn GT    |
| Data 06 | 06_hybrid_addresses_600.csv         | 600    | lai          | Pha trộn thực thể hai thời kỳ (C1, C2, C3) |
| Data 07 | 07_bidirectional_pairs_verified.csv | 600    | Ánh xạ       | 100% OSM diff quan sát thực tế (M-N, N-I)  |

- **Quy cách đồng nhất:** Định dạng UTF-8-sig, không có dòng trùng lặp, mã băm khớp 100% trong run\_manifest.json.

## Hệ thống Chỉ số Đo lường Độc lập & Khắt khe

- **1. Độ chính xác Tuyệt đối (Exact Match - EM):**

$$\text{Exact Match}(\hat{y}) = \bigwedge_{f \in F^*} \mathbb{I}(\text{Norm}(\hat{y}_f) = \text{Norm}(y_f^*)) \quad (\text{với } F^* = \{5 \text{ trường cốt lõi}\})$$

- **2. Macro-averaged Token F1 từng trường:**

$$F1_f = \frac{2 \cdot \text{Precision}_f \cdot \text{Recall}_f}{\text{Precision}_f + \text{Recall}_f}, \quad \text{Avg\_F1} = \frac{1}{|F^*|} \sum_{f \in F^*} F1_f$$

- **3. Tỷ lệ Bỏ sót (Missing Rate) & Tỷ lệ Ảo giác (Hallucination Rate):**

- **Missing Rate:** Nhãn thực tế  $y_f^* \neq \emptyset$  nhưng mô hình dự đoán  $\hat{y}_f = \emptyset$ .
- **Hallucination Rate:** Nhãn thực tế  $y_f^* = \emptyset$  (cấp Quận ở hệ 2 cấp) nhưng mô hình tự bịa  $\hat{y}_f \neq \emptyset$ .

# Kết quả Sơ bộ Sprint 2

## Đối đầu 2 Hệ Baseline Dựa trên Luật & CRF (13.000 Lượt chạy)

| Tập Benchmark     | Công cụ / Chế độ    | Exact Match  | Partial | Avg F1 | Missing | Hallucination        |
|-------------------|---------------------|--------------|---------|--------|---------|----------------------|
| Data 01 (Hệ mới)  | Libpostal           | 0.2%         | 91.7%   | 0.448  | 22.3%   | 77.5%                |
|                   | VietnamAdminUnits   | <b>97.3%</b> | 2.7%    | 0.790  | 2.7%    | 0.0%                 |
| Data 02 (Nhiều)   | Libpostal           | 0.1%         | 51.5%   | 0.332  | 66.2%   | 26.6%                |
|                   | VietnamAdminUnits   | <b>21.7%</b> | 69.4%   | 0.748  | 76.7%   | 0.0%                 |
| Data 03 (Cũ sạch) | Libpostal           | 0.1%         | 62.4%   | 0.376  | 98.3%   | 0.0%                 |
|                   | VietnamAdminUnits   | <b>72.9%</b> | 24.8%   | 0.904  | 26.3%   | 0.0%                 |
| Data 04 (Thiếu)   | Libpostal           | 15.0%        | 26.6%   | 0.395  | 39.8%   | 33.0%                |
|                   | VietnamAdminUnits   | <b>26.0%</b> | 30.8%   | 0.574  | 60.4%   | 6.8%                 |
| Data 06 (Lai)     | Libpostal           | 0.3%         | 83.0%   | 0.504  | 98.2%   | 0.0%                 |
|                   | VNAdmin (FROM_2025) | <b>0.0%</b>  | 92.7%   | 0.656  | 100.0%  | 0.0%                 |
| Data 07 (Ảnh xạ)  | VNAdmin (Converter) | <b>97.7%</b> | 0.0%    | 0.988  | 0.3%    | <b>12 ca sai M-N</b> |

**Phạm vi đánh giá:** Kết quả trên ghi nhận đối đầu sơ bộ giữa **2 baseline** (Dựa trên luật và CRF). **4 baseline còn lại** (Deepparse zero-shot/fine-tuned, PhoBERT-CRF, String-match) được đưa vào kế hoạch thực nghiệm chuyên sâu ở Sprint 3.

# Second Result

## Các Ca Lỗi Thực tế Điển hình Truy vết từ Dữ liệu Chạy (Case Studies)

| Mã ca & Cơ chế                      | Chuỗi đầu vào (Input)                                         | Dự đoán Baseline                                                                | Đáp án (Ground Truth)                                    | Phân tích kỹ thuật                                             |
|-------------------------------------|---------------------------------------------------------------|---------------------------------------------------------------------------------|----------------------------------------------------------|----------------------------------------------------------------|
| <b>D01_0000</b><br>Ảo giác Quận     | 394, Đường Lý Thường Kiệt, Phường Phù Khê, Bắc Ninh           | <b>Libpostal:</b><br>Phường: (rỗng)<br>Quận: "phường phù"                       | Phường: <b>Phù Khê</b><br>Quận: <b>(rỗng - hệ 2 cấp)</b> | Cắt xén cụm từ Phường để bịa Quận do học vẹt mô hình 3 cấp cũ. |
| <b>D02_N0005</b><br>Sụp đổ do OCR   | Số 12 Duong Le Loi, P.Ben Nghe, Q1, TPHCM                     | <b>VietnamAdminUnits:</b><br>Bỏ sót toàn bộ Phường/Quận                         | Phường: <b>Bến Nghé</b><br>Quận: <b>Quận 1</b>           | Mất dấu tiếng Việt khiến cây tra từ điển trượt dài.            |
| <b>D06_0000</b><br>Địa chỉ lai      | 6, Ngõ 42 Trần Bình Trọng, P.Phương Liểu, TX.Quế Võ, Bắc Ninh | <b>VNAdmin (mode 2025):</b><br>Đường: ...P.Phương Liểu<br>Phường: <b>Quế Võ</b> | Phường: <b>Phương Liểu</b><br>Quận: <b>TX. Quế Võ</b>    | Parser 2025 thấy cấp quận cũ thì nuốt cả phường vào đường.     |
| <b>D07_0018</b><br>Silent Error M-N | 36, Phố Trần Phú, P.Điện Biên, Q.Ba Đình, Hà Nội              | <b>VNAdmin (Converter):</b><br>Phường: <b>Phường Hoàn Kiếm</b>                  | Phường: <b>Phường Ba Đình</b>                            | Fallback isDefaultNewWard gán sai đích âm thầm.                |

# Vướng mắc & Rủi ro (Blockers)

## Nhận diện Các Điểm nghẽn Kỹ thuật & Giải pháp Tháo gỡ

- **Khối lượng gán nhãn thủ công lớn (Label Studio):** Tập hóa đơn thật Viet-Receipt (~2.000 mẫu) và tập mốc định vị (~500 mẫu) đòi hỏi nhiều nhân lực gán nhãn span 11 lớp và đo độ đồng thuận Cohen's Kappa.  
→ *Giải pháp tháo gỡ:* Áp dụng cơ chế tiền gán nhãn bán tự động (Weak supervision / Regex pre-annotation) để tăng tốc độ gán nhãn tay.
- **Mơ hồ trong quan hệ chia tách  $M - N$  khi thiếu số nhà:** Điểm gây lớn nhất là khi một xã cũ phân rã thành nhiều phường mới (như 12 ca sai ở Data 07), nếu chuỗi đầu vào không có số nhà thì không thể xác định ranh giới bằng luật.  
→ *Giải pháp tháo gỡ:* Xây dựng mô-đun Graph RAG kết hợp tra cứu tri thức địa phương.
- **Ràng buộc tài nguyên tính toán (GPU 16GB):** Giới hạn bộ nhớ trên GPU đơn (Google Colab / Kaggle) khi huấn luyện các mô hình Pretrained Language Models (PhoBERT/ViBERT).  
→ *Giải pháp tháo gỡ:* Sử dụng kỹ thuật LoRA/Adapter và mixed-precision (FP16) để tối ưu hóa VRAM.

# Kế hoạch Triển khai Sprint 3

## Kế hoạch Trọng tâm Sprint 3: Mô hình hóa & Hoàn thiện Baseline

- **1. Thực nghiệm 4 Baseline còn lại:** Triển khai và đánh giá đối đầu đầy đủ với:
  - Deepparse zero-shot và Deepparse fine-tuned (FastText / CRF).
  - Mô hình chuỗi lai PhoBERT-CRF.
  - Heuristic string-matching (Fuzzy match / Jaro-Winkler).
- **2. Huấn luyện Mô hình Đề xuất (Proposed Model):**
  - Fine-tune **PhoBERT / ViBERT** cho bài toán phân tách thực thể theo Lược đồ 11 nhãn span.
  - Thiết kế mô-đun nhận biết cấu trúc động (2 cấp vs 3 cấp) nhằm triệt tiêu hoàn toàn lỗi ảo giác Quận (77,5%).
- **3. Hoàn thiện Dữ liệu Gán nhãn Bán thủ công:**
  - Đẩy nhanh tiến độ nghiệm thu tập hóa đơn thật Viet-Receipt và tập mốc định vị trên Label Studio.
  - Đóng gói Gazetteer đa phiên bản có gán nhãn thời gian hiệu lực và mã định danh chuẩn.

# Table of Contents

- 1 Introduction
- 2 Preliminaries and Problem Statement
- 3 Related Works
- 4 Proposed Method
- 5 Experiments and Results
- 6 Conclusion**



# - THE END -

## **Acknowledgements:**

Xin chân thành cảm ơn Thầy Quan Thành Thơ và Quý Thầy/Cô trong Hội đồng.

## **Contact:**

[huy.nguyenquang2311202@hcmut.edu.vn](mailto:huy.nguyenquang2311202@hcmut.edu.vn)