



Vietnamese Address Parsing and Resolution across an Administrative Temporal Boundary: A Benchmark Dataset and a Two-Stage Model

Supervisor: Quan Thanh Tho

Student: Nguyen Quang Tung - 2313817

Student: Nguyen Quang Huy - 2311202

Faculty of Computer Science & Engineering
Ho Chi Minh City University of Technology, Vietnam National University Ho Chi Minh City

September 21, 2026

Table of Contents

- 1 Introduction**
- 2 Preliminaries and Problem Statement**
- 3 Related Works**
- 4 Proposed Method**
- 5 Experiments and Results**
- 6 Conclusion**



Sprint 2: Mục tiêu vs Kết quả Đạt được

Tổng kết Hạng mục Công việc & Kết quả Thực hiện trong Sprint 2

1. Về Phát triển Dữ liệu Benchmark (Tự động hóa & lọc dữ liệu):

- **Mục tiêu đặt ra:** Sinh ~800 thiếu trường, ~600 địa chỉ lai, ~600 cặp ánh xạ; trích xuất snapshot và diff từ OSM full-history.
- **Đạt được:** Hoàn thành 100% qua code: đúng **800 mẫu thiếu trường** (Data 04), **600 mẫu địa chỉ lai** (Data 06) và **600 cặp ánh xạ hai chiều** (Data 07) được đối chiếu thực tế qua OSM diff.
- **Nghiệm thu:** Đóng băng Bộ 6 tập benchmark (5.500 mẫu) kèm mã băm SHA-256 xác thực bất biến trong `run_manifest.json`.

2. Về Thực nghiệm Baseline & Đóng gói Lý thuyết:

- **Mục tiêu đặt ra:** Đánh giá baseline `vietnamadminunits` và `Libpostal`, thu thập số liệu và ca lỗi thực tế phủ đủ 4 ca mơ hồ (A, B, C, D).
- **Đạt được:** Chạy **13.000 lượt dự đoán** sơ bộ trên 2 hệ baseline, lưu 100% log phản hồi thô không crash; thu thập đầy đủ bằng chứng định lượng và các ca lỗi thực tế phủ đủ A, B, C, D.
- **Đạt được:** Hoàn thành bản thảo chi tiết **Chương 1** (Động lực) và **Chương 2** (Cơ sở lý thuyết).



Research Gaps (Hiệu chỉnh): Tiền lệ & Hệ quy chiếu Ẩn

Làm rõ Giới hạn Tiền lệ & Bản chất Chuỗi Địa chỉ Tự do

- **G1 (Hiệu chỉnh — Giới hạn Tiền lệ & Đóng góp Đề tài):**

- Đã có tiền lệ chuẩn hóa địa chỉ tiếng Việt (Bui & Tran 2019) và các thư viện cộng đồng (vietnamadminunits, undertheseanlp/address).
- Tuy nhiên, **CHƯA có benchmark học thuật** trên địa chỉ dân dụng thật, được **gắn nhãn hệ quy chiếu thời gian ở cấp bản ghi**.

- **G6 (Khoảng trống Mô hình hóa Hệ quy chiếu Ẩn):**

- Các hướng liên quan (*temporal Entity Resolution*, typology biến đổi đơn vị, LUT/GCT, gazetteer theo thời điểm) đều giả định: đơn vị đã có mã · biết rõ hệ quy chiếu · số cấp cố định.
- **Chưa hướng nào áp dụng cho chuỗi địa chỉ tự do có hệ quy chiếu ẩn**, người dùng viết tự nhiên không khai báo mốc thời gian.

Research Gaps (Bổ sung): Biến đổi Tầng Khung & Hai chiều

Đặc thù Đột phá của Đợt Sáp nhập 2025 tại Việt Nam

- **G7 (Khoảng trống Tầng Cấu trúc Khung 3 → 2 cấp):**

- Cải cách hành chính năm 2025 tại Việt Nam **xóa hẳn một cấp hành chính trung gian** (3 → 2 cấp: xóa cấp quận/huyện trong hệ mới).
- Đây là thay đổi ở **tầng KHUNG cấu trúc phân cấp**, không phải tầng đơn vị. **Chưa có bất kỳ công trình nào** trong và ngoài nước xử lý trường hợp bỏ hẳn một cấp hành chính.

- **G8 (Khoảng trống Mất mát Thông tin khi Phân giải Hai chiều):**

- Quá trình phân giải hai chiều bị mất thông tin bản chất: quan hệ gộp ($N \rightarrow 1$) khi đảo chiều ngược lại sẽ thành tách ($1 \rightarrow N$), dẫn tới phân rã bất định nếu thiếu số nhà hoặc mốc định vị.
- **Chưa có công trình nào đo lường mức độ mất mát thông tin này** trên dữ liệu thực nghiệm thực tế.

Mô hình hóa 4 Tình huống Không gian - Thời gian (A, B, C, D)

- **Tình huống A (Ánh xạ xuôi Cũ → Mới):** Đơn vị hành chính cũ chuyển sang mới theo quan hệ: 1 – 1 (giữ nguyên), $N - 1$ (hợp nhất), $1 - N$ (chia tách), $M - N$ (chia tách và tái cơ cấu phức tạp).
- **Tình huống B (Ánh xạ ngược Mới → Cũ):** Truy xuất lịch sử địa chỉ từ hệ mới phục vụ lưu trữ hồ sơ pháp lý (Bài toán phân rã $1 \rightarrow N$ bất định nếu thiếu số nhà).
- **Tình huống C (Địa chỉ Lai):** Chuỗi địa chỉ pha trộn: C1 (Phường mới + Huyện cũ + Tỉnh cũ), C2 (Phường mới + Huyện cũ + Tỉnh mới), C3 (Phường cũ + Huyện cũ + Tỉnh mới).
- **Tình huống D (Nhập nhầm Không gian):** Đồng âm tên xã/phường diện rộng, mất neo phân cấp khi bị khuyết quận/huyện hoặc gặp nhiễu OCR.

Phương pháp Tiếp cận Dựa trên Quy tắc (Rule-based / Gazetteer)

- **Đại diện tiêu biểu:** Thư viện vietnamadminunits (bộ từ điển hành chính kết hợp Trie / Regex).
- **Cơ chế hoạt động:** Tra cứu từ khóa hành chính ngược từ phải sang trái (Tỉnh → Huyện → Xã), bóc tách phần còn lại thành Số nhà và Tên đường.
- **Ưu điểm:**
 - Tốc độ xử lý cực nhanh, bộ nhớ thấp.
 - Độ chính xác tuyệt đối (97,3%) khi chuỗi đầu vào sạch chuẩn, đúng chính tả tiếng Việt.
- **Nhược điểm cốt tử:**
 - Cực kỳ nhạy cảm với lỗi chính tả và nhiễu OCR (tỷ lệ đúng sụp đổ xuống 21,7%).
 - Tê liệt trước địa chỉ khuyết thiếu hoặc cấu trúc đảo thứ tự.
 - Dễ gây ra lỗi âm thầm (*Silent Error*) ở quan hệ chia tách $M - N$ do fallback gán bừa vào xã mặc định.

Phương pháp Gán nhãn Chuỗi Cổ điển (CRF / Libpostal)


- **Đại diện tiêu biểu:** Thư viện Libpostal (OpenVenues — thư viện C phân tích địa chỉ đa ngôn ngữ hàng đầu thế giới).
- **Cơ chế hoạt động:** Mô hình Trường ngẫu nhiên có điều kiện (CRF) huấn luyện trên hàng triệu địa chỉ OSM toàn cầu.
- **Ưu điểm:**
 - Khả năng chịu lỗi biến thể từ vựng tốt hơn rule-based, tốc độ thực thi rất nhanh.
- **Nhược điểm cốt tử:**
 - Mô hình bị đóng băng trên cấu trúc 3 cấp cũ: Bắt buộc chuỗi phải có cấp Quận/Huyện.
 - Ảo giác Quận nặng nề (77,5%): Khi gặp địa chỉ hệ mới 2 cấp (không có quận), mô hình tự ý xé cụm từ Phường/Xã để gán cho Quận (Exact Match chạm đáy 0,2%).
 - Hoàn toàn thất bại trước địa chỉ lai (0,3% Exact Match).

Table of Contents

- 1 Introduction
- 2 Preliminaries and Problem Statement
- 3 Related Works
- 4 Proposed Method**
- 5 Experiments and Results
- 6 Conclusion



Kiến trúc Pipeline Trích xuất Dữ liệu & Tạo Benchmark



Component 1

Trích xuất OSM Full-History & Lọc Thời gian Lịch sử

- **Nguồn gốc thô & Mốc lọc:** Tập vietnam-internal.osh.pbf (756.709.921 bytes, SHA-256 xác thực). Dùng pyosmium duyệt mốc cắt lịch sử trước đợt sắp nhập:

$$\text{Timestamp}(v_i) \leq 2025-06-30T23:59:59Z \wedge \text{visible} = \text{True}$$

- **Khối lượng thô ban đầu (trước lọc địa lý):** Trích xuất được tổng cộng **26.961 thực thể** có gắn thẻ địa chỉ addr:*, gồm **15.749 node** và **11.212 way**.
- **Đo lường chất lượng trên tập 15.749 node thô:**
 - Node sạch hoàn chỉnh (đủ cả 5 trường): **6.008 / 15.749 node** (38,15%).
 - Node thiếu tự nhiên (≥ 1 trường bị khuyết): **9.741 / 15.749 node** (61,85%, chủ yếu thiếu số nhà).
- **Snapshot cân bằng 3 miền (sau lọc địa lý & làm sạch):**
 - Lọc ra tập cân bằng **16.242 bản ghi** (gồm cả node và way: Bắc 61,6%, Nam 30,3%, Trung 8,1%).
 - Trong đó có **8.848 bản ghi sạch hoàn hảo** (đủ 5 trường) được chọn làm nguồn chuẩn để lấy mẫu 1.500 dòng cho Data 03 và tạo Data 04.

Lập Hồ sơ Nhiễu từ Hóa đơn Thực tế (Viet-Receipt-VQA)

- Khảo sát 1.659 hóa đơn bán lẻ thô → làm sạch và chọn lọc 146 chuỗi địa chỉ giao dịch thực tế.
- Đo lường định lượng các dạng sai lệch văn bản thực tế (`configs/noise_params.json`):

Dạng nhiễu thực tế	Tần suất	Biểu hiện cụ thể
Viết tắt hành chính	60,3%	P., Q., TP., TX., TT., P.Q.
Bỏ dấu / Lỗi Telex	45,5%	Phuong Ben Nghe, Q.Binh Thanh, Duong
Lỗi OCR ký tự hình học	9,0%	Nhầm 0 ↔ O, Đ ↔ D/E, dấu phẩy ↔ chấm
Đảo trật tự phân cấp	9,5%	Đưa Quận lên trước đường, Số nhà đặt ở cuối
Nhiều dấu phân cách	100,0%	Dấu gạch ngang, thiếu khoảng trắng, nhiều dấu phẩy

- Đóng vai trò làm cơ sở tham số hóa cho generator sinh Data 02 nhiễu tổng hợp có kiểm soát.

Sinh Dữ liệu Benchmark Chuyên đề Có kiểm soát (Data 04, 06, 07)

- **Data 04 — Thiếu trường có kiểm soát ($N = 800$):**

- Sinh từ nguồn sạch (400 cũ, 400 mới) rồi chủ động lược bỏ: khuyết số nhà (348), khuyết phường (241), khuyết cả số nhà và phường (112), khuyết quận (99).
- Bảo toàn 100% các trường GT_* gốc để phục vụ đo lường khả năng phục hồi thông tin.

- **Data 06 — Địa chỉ lai ($N = 600$):**

- Sinh theo 3 mô hình dịch chuyển: C1 (420 mẫu: Phường mới + Huyện cũ + Tỉnh cũ); C2 (120 mẫu: Phường mới + Huyện cũ + Tỉnh mới); C3 (60 mẫu: Phường cũ + Huyện cũ + Tỉnh mới).
- Toàn bộ 600 chuỗi duy nhất 100%, khớp đúng các cạnh trong bảng sáp nhập chuẩn.

- **Data 07 — Cặp ánh xạ hai chiều ($N = 600$ cặp):**

- Kiểm toán 1.631 OSM diffs → lọc đúng 600 cặp quan sát thực tế (356 cặp $M - N$, 244 cặp $N - 1$). Số nhà và tên đường giữ nguyên vẹn qua hai thời kỳ.

Table of Contents

- 1 Introduction
- 2 Preliminaries and Problem Statement
- 3 Related Works
- 4 Proposed Method
- 5 Experiments and Results**
- 6 Conclusion



Bộ 6 Tập Benchmark Đóng băng (v2.0 — SHA-256 Verified)

Tập	Tên tập benchmark	Số mẫu	Hệ quy chiếu	Đặc trưng kỹ thuật cốt lõi
Data 01	01_full_address_new_verified.csv	1.000	mọi	Mô hình 2 cấp tinh gọn, Quan-Huyen rỗng
Data 02	02_raw_noisy_synthetic_1000.csv	1.000	cu & mọi	Nhiều tổng hợp thực tế, giữ 100% GT_*
Data 03	03_real_address_old_1500.csv	1.500	cu	Chuẩn sạch hoàn toàn, đủ cả 5 trường
Data 04	04_missing_fields_800.csv	800	cu & mọi	Khuyết trường có kiểm soát, bảo toàn GT
Data 06	06_hybrid_addresses_600.csv	600	lai	Pha trộn thực thể hai thời kỳ (C1, C2, C3)
Data 07	07_bidirectional_pairs_verified.csv	600	Ánh xạ	100% OSM diff quan sát thực tế (M-N, N-I)

- **Quy cách đồng nhất:** Định dạng UTF-8-sig, không có dòng trùng lặp, mã băm khớp 100% trong run_manifest.json.

Hệ thống Chỉ số Đo lường Độc lập & Khắt khe

- **1. Độ chính xác Tuyệt đối (Exact Match - EM):**

$$\text{Exact Match}(\hat{y}) = \bigwedge_{f \in F^*} \mathbb{I}(\text{Norm}(\hat{y}_f) = \text{Norm}(y_f^*)) \quad (\text{với } F^* = \{5 \text{ trường cốt lõi}\})$$

- **2. Macro-averaged Token F1 từng trường:**

$$F1_f = \frac{2 \cdot \text{Precision}_f \cdot \text{Recall}_f}{\text{Precision}_f + \text{Recall}_f}, \quad \text{Avg_F1} = \frac{1}{|F^*|} \sum_{f \in F^*} F1_f$$

- **3. Tỷ lệ Bỏ sót (Missing Rate) & Tỷ lệ Ảo giác (Hallucination Rate):**

- **Missing Rate:** Nhãn thực tế $y_f^* \neq \emptyset$ nhưng mô hình dự đoán $\hat{y}_f = \emptyset$.
- **Hallucination Rate:** Nhãn thực tế $y_f^* = \emptyset$ (cấp Quận ở hệ 2 cấp) nhưng mô hình tự bịa $\hat{y}_f \neq \emptyset$.

Kết quả Sơ bộ Sprint 2

Đối đầu 2 Hệ Baseline Dựa trên Luật & CRF (13.000 Lượt chạy)

Tập Benchmark	Công cụ / Chế độ	Exact Match	Partial	Avg F1	Missing	Hallucination
Data 01 (Hệ mới)	Libpostal	0.2%	91.7%	0.448	22.3%	77.5%
	VietnamAdminUnits	97.3%	2.7%	0.790	2.7%	0.0%
Data 02 (Nhiều)	Libpostal	0.1%	51.5%	0.332	66.2%	26.6%
	VietnamAdminUnits	21.7%	69.4%	0.748	76.7%	0.0%
Data 03 (Cũ sạch)	Libpostal	0.1%	62.4%	0.376	98.3%	0.0%
	VietnamAdminUnits	72.9%	24.8%	0.904	26.3%	0.0%
Data 04 (Thiếu)	Libpostal	15.0%	26.6%	0.395	39.8%	33.0%
	VietnamAdminUnits	26.0%	30.8%	0.574	60.4%	6.8%
Data 06 (Lai)	Libpostal	0.3%	83.0%	0.504	98.2%	0.0%
	VNAdmin (FROM_2025)	0.0%	92.7%	0.656	100.0%	0.0%
Data 07 (Ảnh xạ)	VNAdmin (Converter)	97.7%	0.0%	0.988	0.3%	12 ca sai M-N

Phạm vi đánh giá: Kết quả trên ghi nhận đối đầu sơ bộ giữa **2 baseline** (Dựa trên luật và CRF). **4 baseline còn lại** (Deepparse zero-shot/fine-tuned, PhoBERT-CRF, String-match) được đưa vào kế hoạch thực nghiệm chuyên sâu ở Sprint 3.

Second Result

Các Ca Lỗi Thực tế Điển hình Truy vết từ Dữ liệu Chạy (Case Studies)

Mã ca & Cơ chế	Chuỗi đầu vào (Input)	Dự đoán Baseline	Đáp án (Ground Truth)	Phân tích kỹ thuật
D01_0000 Ảo giác Quận	394, Đường Lý Thường Kiệt, Phường Phù Khê, Bắc Ninh	Libpostal: Phường: (rỗng) Quận: "phường phù"	Phường: Phù Khê Quận: (rỗng - hệ 2 cấp)	Cắt xén cụm từ Phường để bịa Quận do học vẹt mô hình 3 cấp cũ.
D02_N0005 Sụp đổ do OCR	Số 12 Duong Le Loi, P.Ben Nghe, Q1, TPHCM	VNAdminUnits: Bỏ sót toàn bộ Phường/Quận	Phường: Bến Nghé Quận: Quận 1	Mất dấu tiếng Việt khiến cây tra từ điển trượt dài.
D06_0000 Địa chỉ lai	6, Ngõ 42 Trần Bình Trọng, P.Phương Liễu, TX.Quế Võ, Bắc Ninh	VNAdmin (mode 2025): Đường: ...P.Phương Liễu Phường: Quế Võ	Phường: Phường Liễu Quận: TX. Quế Võ	Parser 2025 thấy cấp quận cũ thì nuốt cả phường vào đường.
D07_0018 Silent Error M – N	36, Phố Trần Phú, P.Điện Biên, Q.Ba Đình, Hà Nội	VNAdmin (Converter): Phường: Phường Hoàn Kiếm	Phường: Phường Ba Đình	Fallback isDefaultNewWard gán sai đích âm thanh.

Table of Contents

- 1 Introduction
- 2 Preliminaries and Problem Statement
- 3 Related Works
- 4 Proposed Method
- 5 Experiments and Results
- 6 Conclusion**

Vướng mắc & Rủi ro (Blockers)

Nhận diện Các Điểm nghẽn Kỹ thuật & Giải pháp Tháo gỡ

- **Khối lượng gán nhãn thủ công lớn (Label Studio):** Tập hóa đơn thật Viet-Receipt (~2.000 mẫu) và tập mốc định vị (~500 mẫu) đòi hỏi nhiều nhân lực gán nhãn span 11 lớp và đo độ đồng thuận Cohen's Kappa.
→ *Giải pháp tháo gỡ:* Áp dụng cơ chế tiền gán nhãn bán tự động (Weak supervision / Regex pre-annotation) để tăng tốc độ gán nhãn tay.
- **Mơ hồ trong quan hệ chia tách $M - N$ khi thiếu số nhà:** Điểm gây lớn nhất là khi một xã cũ phân rã thành nhiều phường mới (như 12 ca sai ở Data 07), nếu chuỗi đầu vào không có số nhà thì không thể xác định ranh giới bằng luật.
→ *Giải pháp tháo gỡ:* Xây dựng mô-đun Graph RAG kết hợp tra cứu tri thức địa phương.
- **Ràng buộc tài nguyên tính toán (GPU 16GB):** Giới hạn bộ nhớ trên GPU đơn (Google Colab / Kaggle) khi huấn luyện các mô hình Pretrained Language Models (PhoBERT/ViBERT).
→ *Giải pháp tháo gỡ:* Sử dụng kỹ thuật LoRA/Adapter và mixed-precision (FP16) để tối ưu hóa VRAM.

Kế hoạch Triển khai Sprint 3

Kế hoạch Trọng tâm Sprint 3: Mô hình hóa & Hoàn thiện Baseline

- **1. Thực nghiệm 4 Baseline còn lại:** Triển khai và đánh giá đối đầu đầy đủ với:
 - Deepparse zero-shot và Deepparse fine-tuned (FastText / CRF).
 - Mô hình chuỗi lai PhoBERT-CRF.
 - Heuristic string-matching (Fuzzy match / Jaro-Winkler).
- **2. Huấn luyện Mô hình Đề xuất (Proposed Model):**
 - Fine-tune **PhoBERT / ViBERT** cho bài toán phân tách thực thể theo Lược đồ 11 nhãn span.
 - Thiết kế mô-đun nhận biết cấu trúc động (2 cấp vs 3 cấp) nhằm triệt tiêu hoàn toàn lỗi ảo giác Quận (77,5%).
- **3. Hoàn thiện Dữ liệu Gán nhãn Bán thủ công:**
 - Đẩy nhanh tiến độ nghiệm thu tập hóa đơn thật Viet-Receipt và tập mốc định vị trên Label Studio.
 - Đóng gói Gazetteer đa phiên bản có gán nhãn thời gian hiệu lực và mã định danh chuẩn.

- THE END -

Acknowledgements:

Xin chân thành cảm ơn Thầy Quan Thành Thơ và Quý Thầy/Cô trong Hội đồng.

Contact:

huy.nguyenquang2311202@hcmut.edu.vn